

量子计算 —算法篇

Quantum Computing

网址: www.qubits.top

作者: Calvin Tang

邮箱: 179209347@qq.com

介绍

教程简介：

- 面向对象：量子计算初学者
- 依赖课程：线性代数，量子力学（非必需）

知乎专栏：

https://www.zhihu.com/column/c_1501138176371011584

Github & Gitee 地址：

<https://github.com/mymagicpower/qubits>

<https://gitee.com/mymagicpower/qubits>

* 版权声明：

- 仅限用于个人学习
- 禁止用于任何商业用途

HHL量子算法背景概述

HHL量子算法解决的问题：

线性方程组问题可定义为：给定矩阵 $A \in \mathbb{C}^{n \times n}$ 和向量 $b \in \mathbb{C}^n$ ，找到 $x \in \mathbb{C}^n$ 满足 $Ax = b$ 。而HHL量子算法所要解决的问题就是**求解线性方程**。

HHL量子算法介绍：

HHL量子算法（以三位创始人Aram Harrow，Avinathan Hassidim和Seth Lloyd命名）是一个用量子计算机解决线性问题（求解线性方程组） $Ax = b$ 最优解的算法，广泛的被应用于许多量子机器学习算法中（如支持向量机SVM，主成分分析PCA等）。

- HHL算法相对于经典算法有着指数级的加速
- 但经典算法可以返回精确解，而HHL算法只能返回近似解

HHL量子算法背景概述

对输入 A 和 b 的要求：

- 首先要求 $n \times n$ 的矩阵 A 是一个**厄米矩阵** (Hermitian Matrix) , 即自共轭矩阵 (即 A 的共轭转置矩阵等于它本身 $A^\dagger = A$)
- 其次输入 b 是一个单位向量。(当 A 不是**厄米矩阵**时, 原算法作者在文中也给出了构造**厄米矩阵**的方法)

$$\text{令 } C = \begin{bmatrix} 0 & A \\ A^\dagger & 0 \end{bmatrix} \quad \text{求解 } C y = \begin{bmatrix} b \\ 0 \end{bmatrix} \quad \text{可得 } y = \begin{bmatrix} 0 \\ x \end{bmatrix}$$

实对称矩阵 $A^T = A$

实对称矩阵是所有元素均为实数的对称矩阵，矩阵的转置与自身相同：

$A^T = A$ A^T 的意思是转置

$$\begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & 0 \\ 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

N 阶实对称方阵具有以下重要性质：

- 性质 1：所有特征值均为实数
- 性质 2：所有特征向量均为实向量
- 性质 3：具有 n 个互不相同的特征值
- 性质 4：具有 n 个线性无关的特征向量
- 性质 5：不同特征值对应的特征向量之间是正交的

厄米矩阵 $A^\dagger = A$

希尔伯特空间中的厄米矩阵： $A^\dagger = A$ A^\dagger 的意思是转置共轭

$$A^\dagger = A = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \text{ 实向量空间中的矩阵表示：}$$

$$\begin{array}{c} \left[\begin{array}{cc|cc} 0 & 0 & 0 & 1 \\ 0 & 0 & -1 & 0 \\ \hline 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{array} \right] \end{array}$$

$$A^T = A = \begin{bmatrix} 0 & i \\ i & 0 \end{bmatrix} \text{ 实向量空间中的矩阵表示：}$$


$$\begin{array}{c} \left[\begin{array}{cc|cc} 0 & 0 & 0 & -1 \\ 0 & 0 & 1 & 0 \\ \hline 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{array} \right] \end{array}$$

没有没有共轭条件，其等价的实数矩阵并不对称！

- 结论：
- 1、厄米矩阵 A^\dagger 其等价的实数矩阵是实对称矩阵。
 - 2、所以厄米矩阵具有实对称矩阵同样性质。
 - 3、唯独性质 2 不满足，即所有特征向量均为实向量不成立，有可能是复向量。

矩阵类型对比

通过这张图，我们可以清晰的看到，
实向量空间与希尔伯特空间之间的
对应关系：
厄米矩阵对应实对称矩阵。



特征分解

特征分解 (Eigen decomposition) , **又称谱分解** (Spectral decomposition) 是将矩阵分解为由其特征值 $\{\lambda_i\}$ 和特征向量 $\{v_i\}$ 表示的矩阵 $V = [v_1 \ v_2 \ \dots \ v_n]$ 之积的方法：

$$A = V \begin{bmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_n \end{bmatrix} V^{-1}$$

需要注意只有可对角化矩阵才可以施以特征分解。特征值的集合 $\{\lambda_i\}$, 也称为“谱” (Spectrum) 。

因为**厄米矩阵** (表达自伴算子的矩阵是**厄米矩阵**) 属于正规矩阵，根据正规矩阵的性质可知，其可以对角化。假设 A 是一个复数域正规矩阵，它的特征值为 $\{\lambda_i\}$ ，标准正交基为 $\{|e_i\rangle\}$ ，那么 A 可以分解为：

$$A = \sum_{i=1}^n \lambda_i |e_i\rangle \langle e_i|$$

HHL算法原理

以下内容中将默认A为厄米矩阵（自共轭矩阵），所以可以进行谱分解。

将向量 b, x 分别归一化后采用编码到振幅上的方式映射到量子态 $|b\rangle, |x\rangle$ ，原问题转换为 $A|x\rangle = |b\rangle$ 。

对矩阵 A 进行谱分解有：

$$A = \sum_{j=0}^{N-1} \lambda_j |\mu_j\rangle\langle\mu_j|, \quad \lambda_j \in \mathbb{R}$$

其中 λ_j, μ_j 为矩阵 A 特征值及相应的特征向量，将 $|b\rangle$ 以特征向量 $|\mu_j\rangle$ 为基，线性组合表示得到：

$$|b\rangle = \sum_{j=0}^{N-1} b_j |\mu_j\rangle, \quad b_j \in \mathbb{C}$$

于是原方程组的解 $|x\rangle$ 为：

$$|x\rangle = A^{-1}|b\rangle = \sum_{j=0}^{N-1} b_j A^{-1} |\mu_j\rangle = \sum_{j=0}^{N-1} \frac{b_j}{\lambda_j} |\mu_j\rangle$$

求解量子态 $|x\rangle$ ，可以转换为由量子态 $|b\rangle$ 构造。

$$\begin{aligned} A|\mu_j\rangle &= \lambda_j |\mu_j\rangle \\ \rightarrow A^{-1}A|\mu_j\rangle &= A^{-1}\lambda_j |\mu_j\rangle \\ \rightarrow |\mu_j\rangle &= A^{-1}\lambda_j |\mu_j\rangle \\ \rightarrow A^{-1}|\mu_j\rangle &= \frac{1}{\lambda_j} |\mu_j\rangle \end{aligned}$$

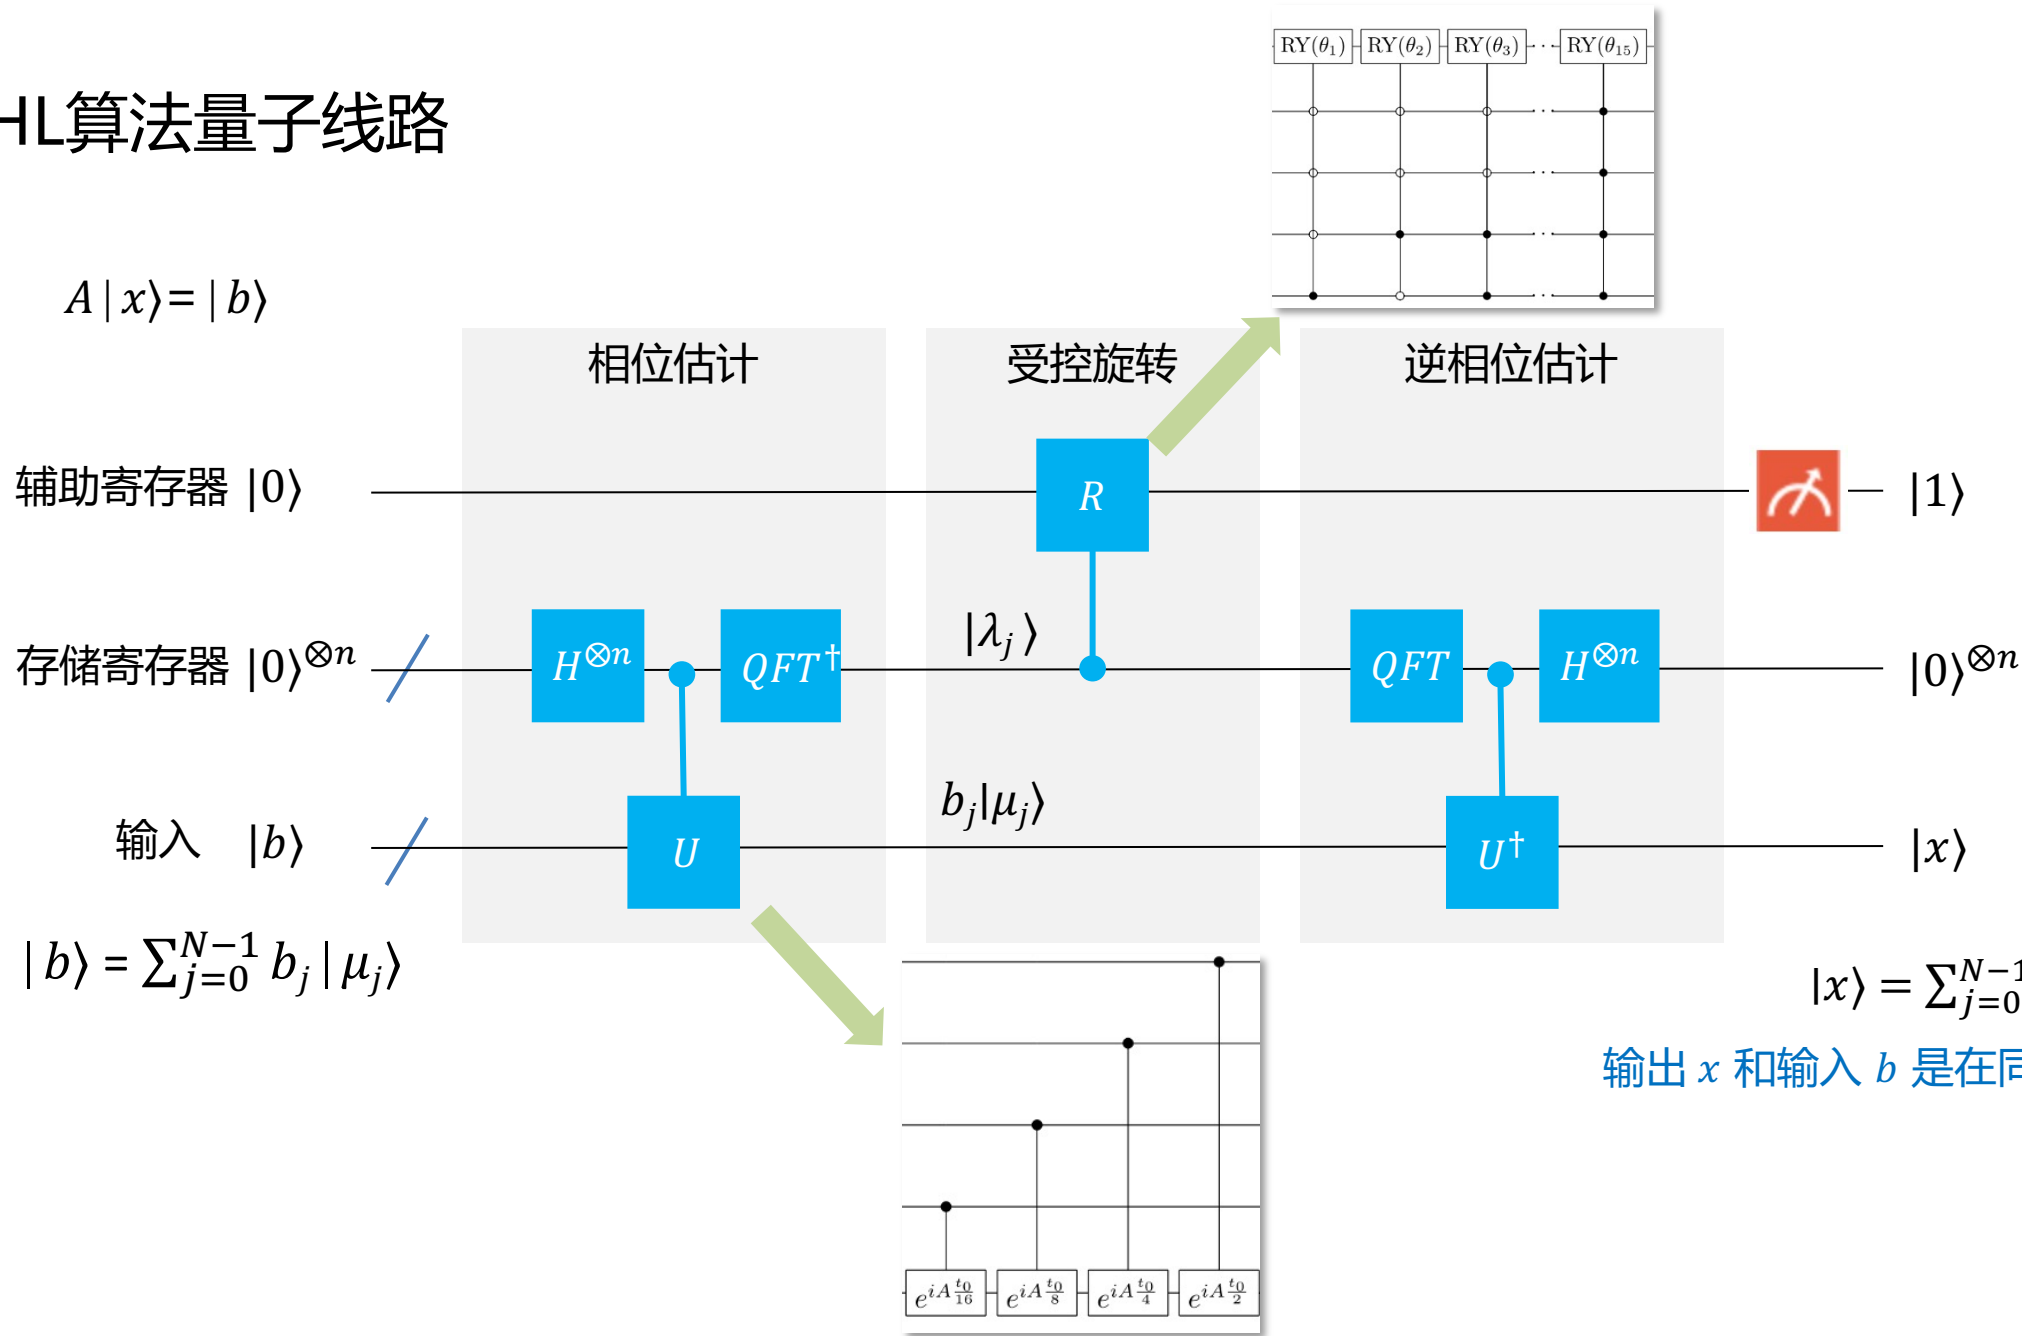
HHL算法原理 - 三个核心步骤

HHL算法主要包含了三大步骤，并需要使用三个寄存器：

- **相位估计**，将矩阵 A 的整数形式特征值全部转移到存储比特的基向量中。
- **受控旋转**，利用受控旋转门将 λ_j 将特征值从存储比特的基向量转移到振幅上，其中 c 是可调参数。
- **逆相位估计**，对特征存储比特及右端项比特进行逆相位估计，将存储比特振幅上的特征值合并到右端项比特上，当辅助比特测量得到特定状态时，在右端项比特上可得到解的量子态。

HHL算法量子线路

$$A|x\rangle = |b\rangle$$



HHL算法过程 – 初态制备 (1/4)

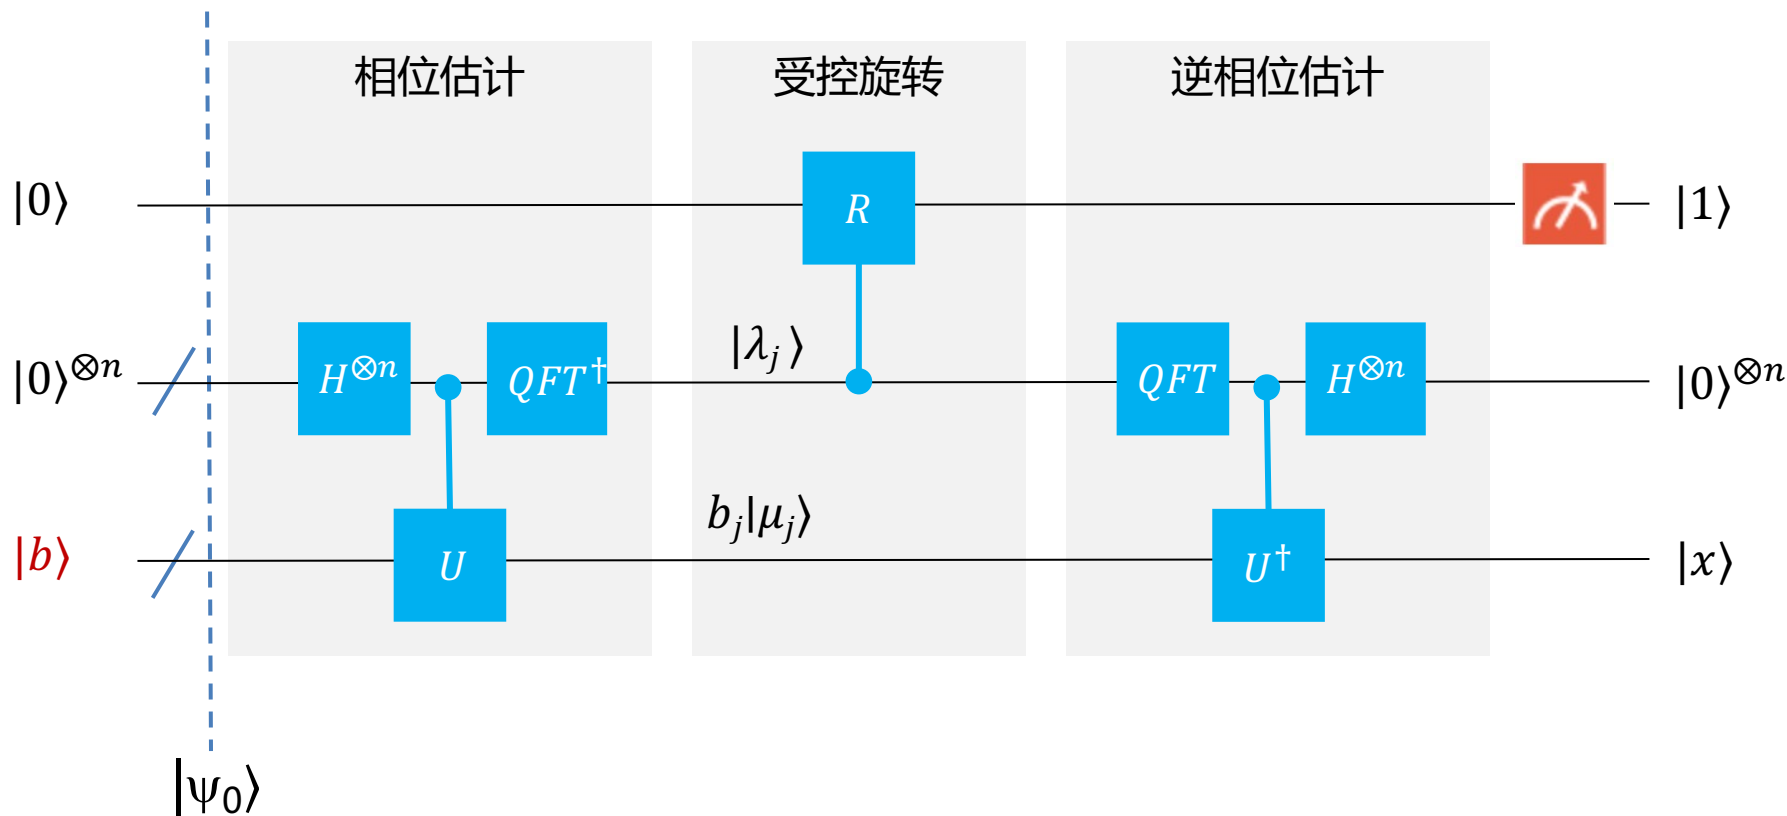
初态制备 :

$$|b\rangle = \sum_{j=0}^{N-1} b_j |j\rangle$$

其中 :

$$b = (b_0 , \dots b_{N-1})$$

$$\sum_{j=0}^{N-1} |b_j|^2 = 1$$



HHL算法过程 - 相位估计 (2/4)

相位估计 (QPE) : 通过QPE提取特征值

为了将矩阵 A 的特征值提取到解量子态的振幅，首先需要完成特征值的提取。 QPE 量子线路可以用于特征值提取。

对 $|0\rangle^{\otimes n} |b\rangle$ 进行一次 QPE 操作，得到：

$$QPE(|0\rangle^{\otimes n} |b\rangle) = \sum_{j=0}^{N-1} b_j |\tilde{\lambda}_j\rangle |\mu_j\rangle$$

其中 $\tilde{\lambda}_j$ 是对应特征值 λ_j 的近似整数。 于是矩阵 A 的特征值信息存入到了基向量 $|\tilde{\lambda}_j\rangle$ 中。

参考来源：<https://pyqpanda-tutorial.readthedocs.io/zh/latest/HHL.html>

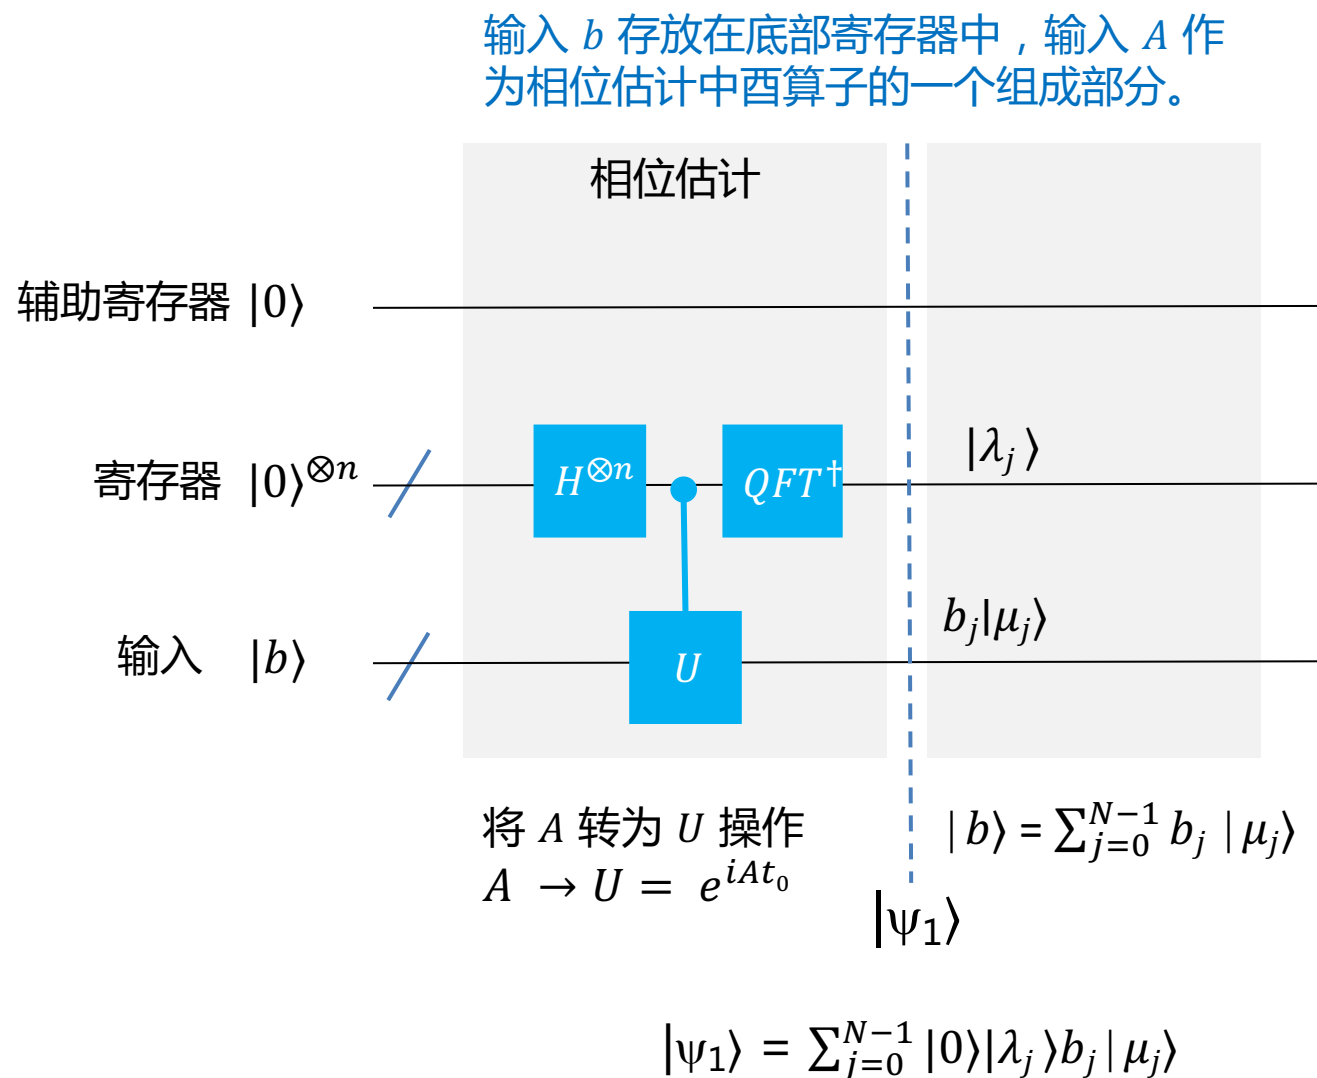
HHL算法过程 - 相位估计 (2/4)

相位估计 (QPE) : 通过QPE提取特征值

- 中间的寄存器会存储一系列的特征值 λ_j (存储在基态 $|\lambda_j\rangle$ 中)
- 而底部寄存器存储的输入 $|b\rangle$ 会在 A 的特征空间上进行分解, 表示为:

$$|b\rangle = \sum_{j=0}^{N-1} b_j |\mu_j\rangle$$

$|\mu_j\rangle$ 是 A 的特征向量, λ_j 为对应特征值。



HHL算法过程 - 受控旋转 (3/4)

受控旋转：通过受控旋转转移特征值

相位估计的第二阶段把存储在概率幅上的值提取到了基态上。而在HHL算法用到了类似的技巧（不过是反向的），即通过受控旋转操作，**将基态中的值提取到了概率幅上**。

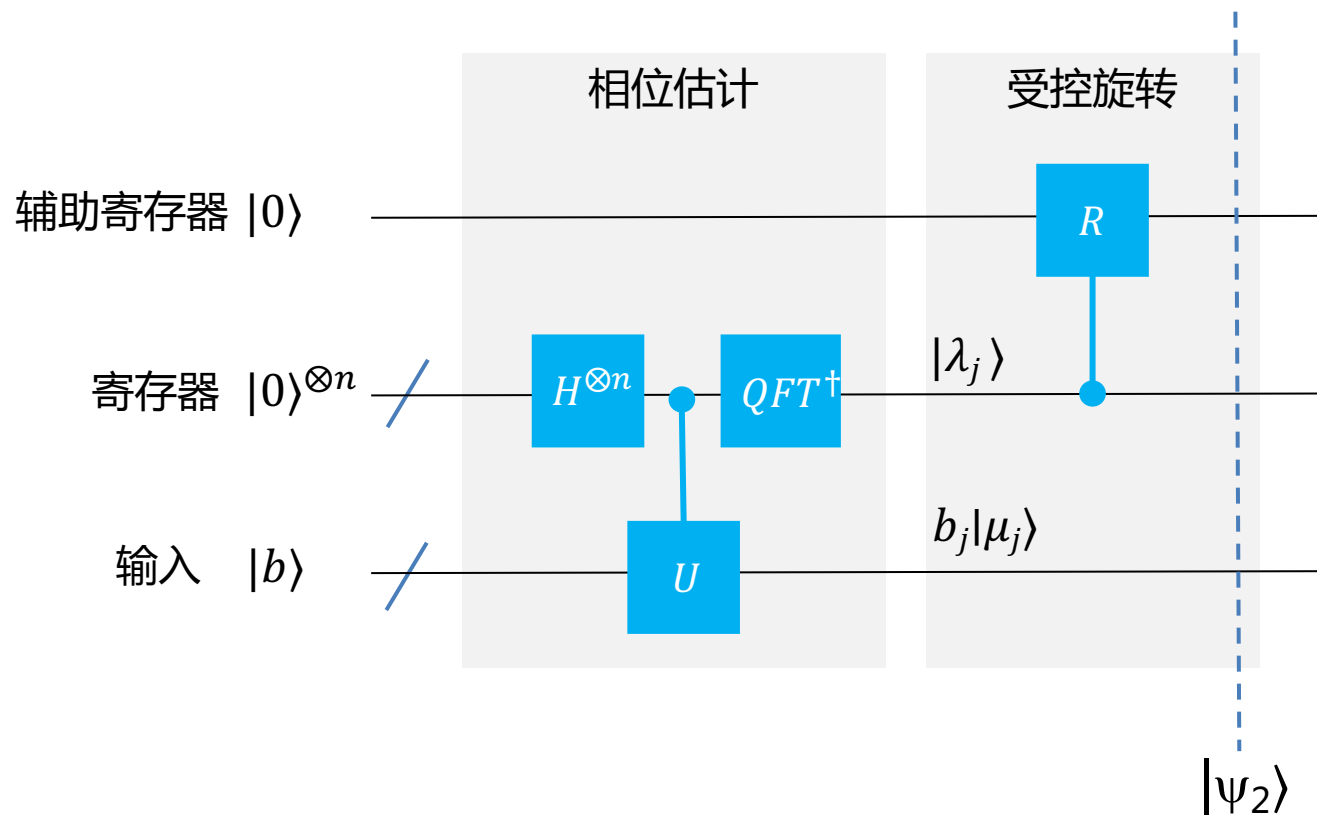
以 $|\lambda_j\rangle$ 作为控制比特对辅助量子比特进行旋转，实现了将基态值的倒数按比例提取到了对应基态的概率幅上。

$$\sqrt{1 - \frac{C^2}{\lambda_j^2}} |0\rangle + \frac{C}{\lambda_j} |1\rangle$$

C 为归一化系数

令 $f(\lambda_j) = C/\lambda_j$ ，将辅助量子比特由基态 $|0\rangle$ 映射到 $|0\rangle$ 和 $|1\rangle$ 的叠加态上，同时将函数值 $f(\lambda_j)$ 提取到了基态 $|1\rangle$ 的概率幅上，如下所示：

$$R |0\rangle = \sqrt{1 - f(\lambda_j)^2} |0\rangle + f(\lambda_j) |1\rangle$$



$$|\psi_2\rangle = \sum_{j=0}^{N-1} \left(\sqrt{1 - \frac{C^2}{\lambda_j^2}} |0\rangle + \frac{C}{\lambda_j} |1\rangle \right) |\lambda_j\rangle b_j |\mu_j\rangle$$

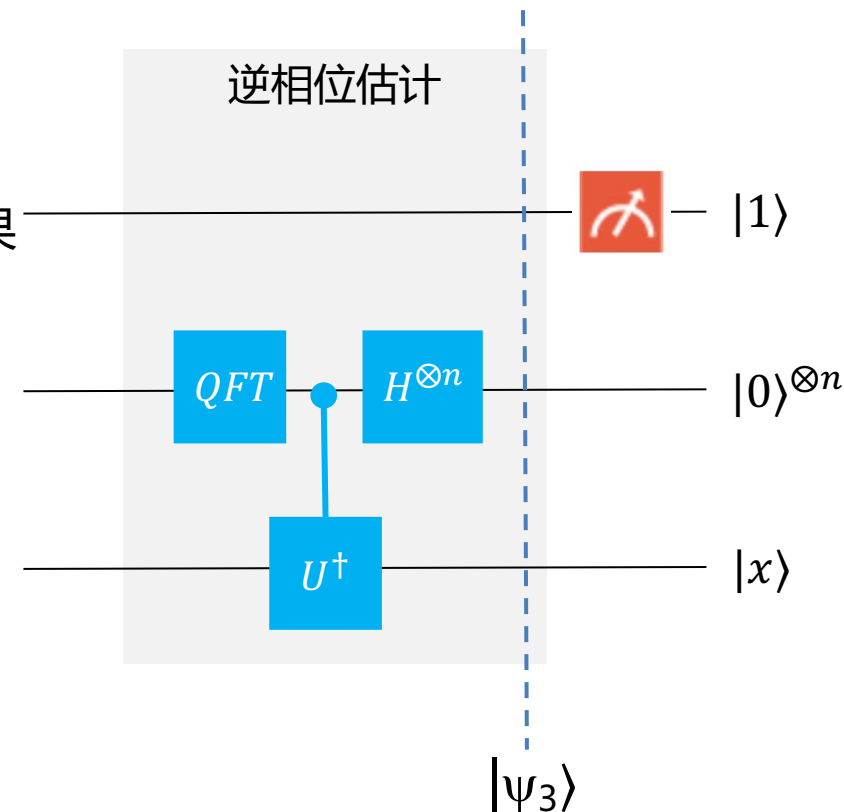
HHL算法过程 - 逆相位估计 (4/4)

逆相位估计：通过逆QPE输出结果量子态

理论上，受控旋转后的量子态已经可以通过测量得到解量子态 $|x\rangle$ 。

但为了避免出现 $|\mu_j\rangle$ 相同但 $|\tilde{\lambda}_j\rangle$ 不同的需要合并的量子态 $\frac{C}{\tilde{\lambda}_j} b_j |1\rangle |\tilde{\lambda}_j\rangle |\mu_j\rangle$ ，应当选择逆 QPE 操作来得到形如 $\frac{C}{\tilde{\lambda}_j} b_j |1\rangle |0\rangle |\mu_j\rangle$ 的结果量子态。对旋转结果进行逆 QPE，有：

$$\begin{aligned} |\psi_3\rangle &= (I \otimes QPE^\dagger) \sum_{j=0}^{N-1} \left(\sqrt{1 - \frac{C^2}{\tilde{\lambda}_j^2}} |0\rangle + \frac{C}{\tilde{\lambda}_j} |1\rangle \right) |\tilde{\lambda}_j\rangle b_j |\mu_j\rangle \\ &= \sum_{j=0}^{N-1} \left(b_j \sqrt{1 - \frac{C^2}{\tilde{\lambda}_j^2}} |0\rangle |0\rangle |\mu_j\rangle + \frac{C}{\tilde{\lambda}_j} b_j |1\rangle |0\rangle |\mu_j\rangle \right) \end{aligned}$$



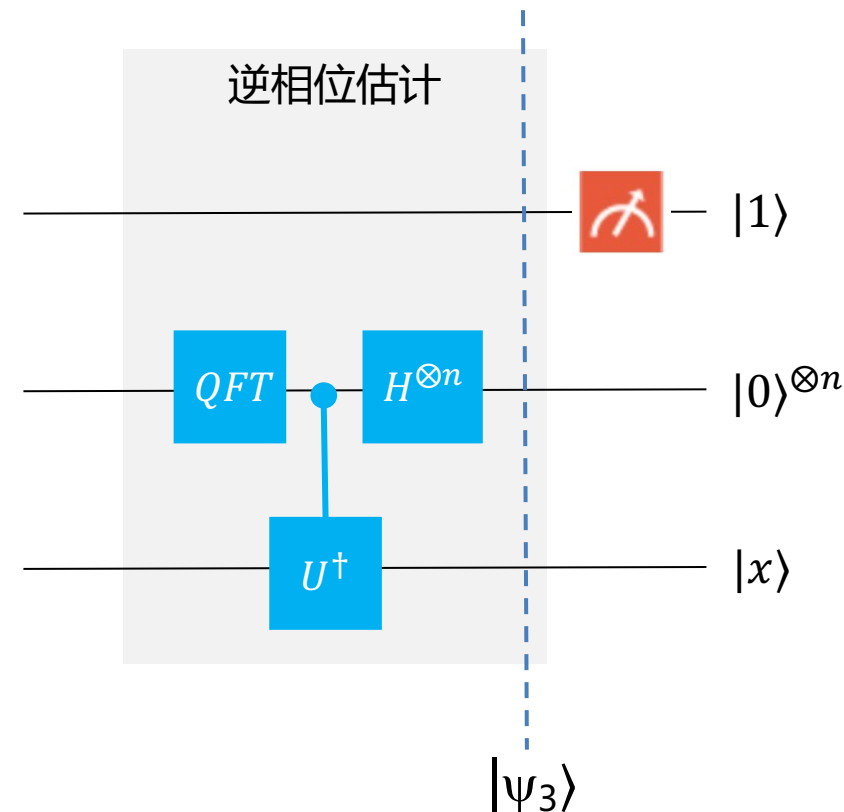
HHL算法过程 - 逆相位估计 (4/4)

逆相位估计：通过逆QPE输出结果量子态

事实上即使是这种形式的结果量子态，由于误差的存在，依然无法在第一个和第二个量子寄存器分别为 $|1\rangle, |0\rangle$ 的情况下以概率 1 得到解量子态：

$$|x\rangle = A^{-1}|b\rangle = \sum_{j=0}^{N-1} b_j A^{-1} |\mu_j\rangle = \sum_{j=0}^{N-1} \frac{b_j}{\lambda_j} |\mu_j\rangle$$

HHL算法充分利用了量子相位估计提取特征值信息的功能，巧妙构造了受控旋转门从存储比特的基向量中抓取特征值存入振幅，最后利用逆相位估计还原存储量子比特，从而得到了振幅含特征值的方程解。



HHL算法过程 - 逆相位估计 (4/4)

逆相位估计：

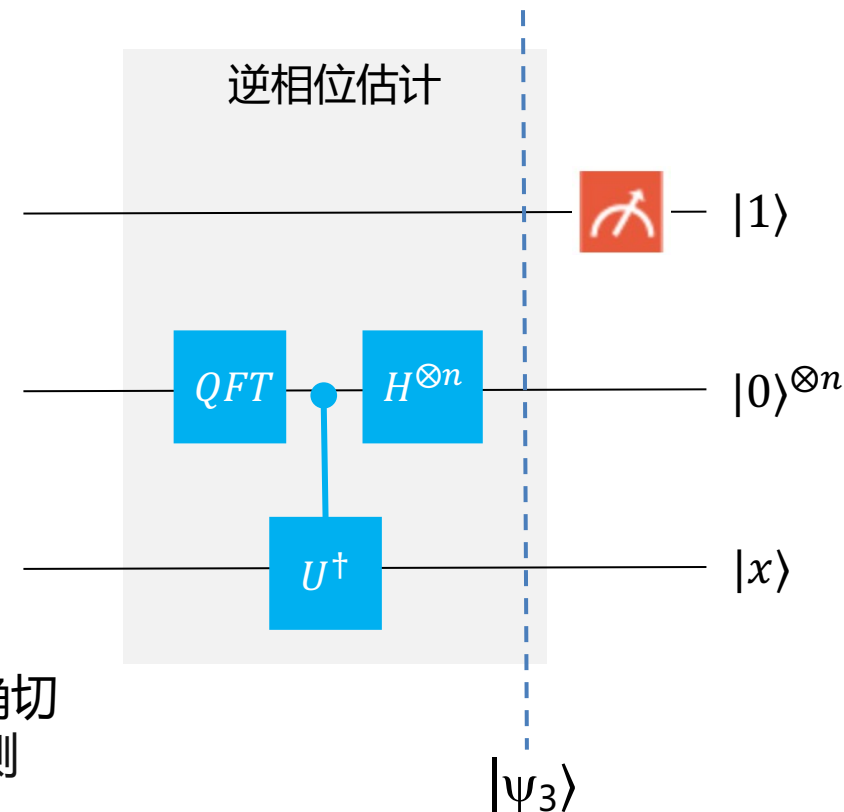
执行逆相位估计，将 $|\lambda_j\rangle$ 转换为 $|0\rangle^{\otimes n}$ 。

对辅助量子比特进行测量，当测量得到 1 时，原来的寄存器由一系列 $|\lambda_j\rangle$ 的叠加变为 $f(\lambda_j)|1\rangle$ 的叠加。

基态 $|\lambda_j\rangle$ 中的值按照 $f(\lambda_j)$ 的比例被提取到了基态 $|\lambda_j\rangle$ 的概率幅上。此时：

$$|x\rangle = \sum_{j=0}^{N-1} \frac{b_j}{\lambda_j} |\mu_j\rangle$$

* 最后得到的 $|x\rangle$ ，各分量的振幅并没有显式地得到，我们并不能读出 x 的确切值是什么。不过我们能够得到一个关于 x 的整体特性。比如目的是求某个观测量 M 在 $|x\rangle$ 上的期望 $\langle x|M|x\rangle$ 。对于 x 的确切值并不是非要提取出来的应用，HHL 算法还是相当高效的。





Thank

You